

# Rappels sur les tests

Alain Quartier-la-Tente

2022-03-12

## Tests de racine unitaire

### Séries temporelles et tendances

Pour modéliser une série avec tendance on peut envisager deux cas :

1. Modèle trend-stationnaire :  $TS_t = DT(t) + MA_t$  avec  $DT(t)$  une tendance déterministe et  $MA_t$  un processus stationnaire avec une représentation  $MA(\infty)$ . Par exemple :

$$TS_t = a + bt + MA_t$$

2. Modèle avec racine unité :

$$(1 - B)UR_t = \underbrace{b}_{drift} + MA_t, \quad UR_0 = a$$

On a donc :

$$UR_t = a + bt + \sum_{i=1}^t \varepsilon_t \text{ où } \sum_{i=1}^t \varepsilon_t \text{ est la tendance stochastique.}$$

On a  $\mathbb{V}[TS_t] = \mathbb{V}[MA_t]$  indépendante du temps mais  $\mathbb{V}[UR_t] = t\sigma^2$

## Tests de racine unité

### Test de Dickey-Fuller

On distingue généralement 4 cas :

1.  $X_t = \rho X_{t-1} + \varepsilon_t$  avec  $(H_0) : \rho = 1$  (et  $(H_1) : |\rho| < 1$ )
2.  $X_t = c + \rho X_{t-1} + \varepsilon_t$  avec  $(H_0) : \rho = 1, c = 0$
3.  $X_t = c + \rho X_{t-1} + \varepsilon_t$  avec  $(H_0) : \rho = 1, c \neq 0$
4.  $X_t = c + bt + \rho X_{t-1} + \varepsilon_t$  avec  $(H_0) : \rho = 1, b = 0$

Comme le Modèle AR(1) est trop simple, on considère généralement un modèle AR(p) :

$$X_t - \mu = \sum_{i=1}^p \Phi_i(X_{t-i} - \mu) + \varepsilon_t$$

C'est le test de Dickey-Fuller Augmenté (ADF).

On rejette lorsque  $\hat{t}_{stat} < DF_\alpha$ .

Sous R, utiliser par exemple `fUnitRoots::adfTest()`, `tseries::adf.test()` ou `urca::ur.df()`<sup>1</sup> (qui permet une sélection automatique des retards).

<sup>1</sup>Voir [https://new.mmf.lnu.edu.ua/wp-content/uploads/2018/03/enders\\_applied\\_econometric\\_time\\_series.pdf](https://new.mmf.lnu.edu.ua/wp-content/uploads/2018/03/enders_applied_econometric_time_series.pdf) ou <https://stats.stackexchange.com/questions/24072/interpreting-rs-ur-df-dickey-fuller-unit-root-test-results> pour comprendre les sorties

## Test de Phillips-Perron

Tests de  $(H_0) : \rho = 1$  dans des modèles semi-paramétriques sous la forme :

$$\begin{cases} X_t = \rho X_{t-1} + u_t \\ X_t = c + \rho X_{t-1} \\ X_t = c + bt + \rho X_{t-1} \end{cases}$$

avec  $u_t$  un terme d'erreur très général.

Sous R : `tseries::pp.test` (troisième forme) ou `urca::ur.pp()`.

## Test KPSS

Test d'hypothèse nulle d'un modèle trend-stationnaire

$$Y_t = \xi t + r_t + \varepsilon_t \quad r_t = r_{t-1} + u_t$$

Avec  $\xi = 0$  si pas de tendance déterministe,  $r_0$  sert de constante et  $u_t$  iid  $(0, \sigma_u^2)$ .

On teste  $(H_0) : \sigma_u^2 = 0$  donc sous  $(H_0)$  la série est *stationnaire* (différent autres tests).

Sous R : `tseries::kpss.test` ou `urca::ur.kpss()`.

## Auto.arima

Il existe beaucoup d'algorithmes automatiques pour la détection automatique de modèles ARIMA (TRAMO étant un des plus connus). Ils permettent de trouver un  $ARIMA(p, d, q)(P, D, Q)_m$ . Décrivons ici l'algorithme utilisé dans `forecast::auto.arima()` :

1. On choisit  $D$  par un test de Canova-Hansen puis  $d$  déterminé en utilisant des tests successifs de KPSS. Ils préfèrent utiliser des tests où  $(H_0)$  est l'absence de racine unitaire car les autres tests ont tendance à biaiser les résultats vers des modèles sur-différenciés.
2. Quatre modèles sont ensuite testés, on en sélectionne un par minimisation de l'AIC :
  - $ARIMA(2, d, 2)(1, D, 1)$
  - $ARIMA(2, d, 2)(0, D, 0)$
  - $ARIMA(1, d, 0)(1, D, 0)$
  - $ARIMA(0, d, 1)(0, D, 1)$
3. On considère 30 variations du modèle retenu :
  - En faisant varier un seul des paramètres  $p, q, P$  ou  $Q$  de  $\pm 1$  ;
  - En faisant varier  $p$  et  $q$  en même temps de  $\pm 1$  ;
  - En faisant varier  $P$  et  $Q$  en même temps de  $\pm 1$  ;
  - En incluant ou non la constante.
  - Si un modèle minimise l'AIC on recommence.

Dans d'autres algorithmes (comme TRAMO ou pickmdl) d'autres tests sont effectués pour chaque modèle testé : tests d'autocorrélation(Ljung-Box à l'ordre 24 pour séries mensuelles), tests de sur-différenciation, de passage au log.